
Локальные методы распределённой оптимизации без подсчёта полного градиента

Студент: Зайнуллин Амир Рустэмович, Б05-206д, ФПМИ МФТИ
Руководитель: Безносиков Александр Николаевич, МФТИ

Цель и задачи дипломной работы

Цель

Разработать распределённый алгоритм невыпуклой оптимизации, который одновременно

- ▶ использует second-order similarity для ускорения сходимости,
- ▶ обходится без вычисления полного градиента ∇f ни в одной точке,
- ▶ использует $\mathcal{O}(d)$ памяти на сервере (не растёт с числом клиентов n).

Задачи

- ▶ проанализировать similarity-методы — SVRS/AccSVRS [17], SVRP [11] — и причину их зависимости от full grad;
- ▶ проанализировать no-full-grad методы — SARAH [20], ZeroSARAH [16], Shuffled SARAH [2];
- ▶ предложить алгоритм, объединяющий оба подхода;
- ▶ доказать невыпуклую сходимость с δ -зависимой сложностью;
- ▶ экспериментально сравнить с baseline методами — SVRS [17], FedAvg [18].

Актуальность

Почему это важно?

- ▶ Размеры моделей и датасетов растут [9] $\Rightarrow$ более распространенным становится распределенное обучение.
- ▶ Главный bottleneck - коммуникация: каждый раунд это $\mathcal{O}(n)$ векторов между сервером и каждым клиентом [8, 12].
- ▶ Прогресс измеряется не числом раундов, а числом передаваемых векторов [1].

Идея similarity

Если данные клиентов из одного распределения, локальные функции f_i удовлетворяют:
 $\|\nabla^2 f_i - \nabla^2 f\| \leq \delta$, причём часто $\delta \ll L$ [7].

Проблема в существующих методах

Две независимые линии работ:

- ▶ similarity-методы [13, 17] требуют full participation в начале каждой эпохи $\Rightarrow \mathcal{O}(n)$ векторов на каждом обновлении;
- ▶ no-full-grad методы [16, 19] не используют δ $\Rightarrow$ зависимость от L (smoothness), не от δ .

Постановка задачи

Распределённая finite-sum задача

$$\min_{x \in \mathbb{R}^d} f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x),$$

$$f_i(x) = \frac{1}{m_i} \sum_{j=1}^{m_i} \ell(g(x, a_j^i), b_j^i).$$

Сервер хранит f_1 , клиенты — $f_2, \dots, f_n$.

Прокс-разложение [17]

Раскладываем f на серверную и клиентскую части:

$$f(w) = (f - f_1)(w) + f_1(w).$$

Прокс-обновление:

$$w_{t+1} = \text{prox}_{\theta f_1} \left(w_t - \theta \nabla (f - f_1)(w_t) \right).$$

$\nabla (f - f_1)(w_t)$ агрегирует клиентов; f_1 — на сервере.

Основная работа алгоритма

Оценить $\nabla (f - f_1)(w_t)$ без подсчета локальных градиентов каждого клиента.

Связанная работа: similarity-методы

Newton-type линия

- ▶ DANE [24] — communication-efficient Newton, только quadratic objectives.
- ▶ AIDE [22], DISCO [27], GIANT [26] — улучшенные Newton-type.
- ▶ SONATA [25], Accelerated Extragradient [13] — оптимальное число раундов $\mathcal{O}\left(\sqrt{\delta/\mu} \log \frac{1}{\varepsilon}\right)$.

Stochastic similarity

- ▶ SVRP, Catalyzed SVRP [11] — stochastic prox с VR, сложность $\mathcal{O}\left((n + \delta^2/\mu^2) \log \frac{1}{\varepsilon}\right)$.
- ▶ SVRS / AccSVRS [17] — accelerated, оптимально по коммуникации $\mathcal{O}\left((n + n^{3/4} \sqrt{\delta/\mu}) \log \frac{1}{\varepsilon}\right)$.

Связанная работа: no-full-gradient методы (centralized)

Эволюция variance reduction

- ▶ SAG/SAGA [4, 23] — таблица всех градиентов, $\mathcal{O}(nd)$ памяти.
- ▶ SARAH/SPIDER [5, 20] — рекурсивный аппроксиматор, но периодический обновление полного градиента.
- ▶ STORM [3], PAGE [15] — momentum / probabilistic switching.

Без full grad вообще

- ▶ ZeroSARAH [16] — первый VR-метод без подсчета полного градиента.
- ▶ Shuffled SARAH [2] — random reshuffle построение аппроксиматора в течении эпохи.
- ▶ Medyakov et al. [19] — продолжение идеи прошлой работы на SVRG, SARAH.

Общий минус

Все методы centralized и не учитывают similarity $\Rightarrow$ сложность зависит от L , не от δ .

Связанная работа: пересечение и гар

Близкие работы

- ▶ Beznosikov & Takáč [2] — Shuffled SARAH под similarity, но strongly convex и centralized.
- ▶ SILVER [21] — non-convex distributed, без full grad, но $\mathcal{O}(nd)$ памяти на сервере .

Незакрытая ниша

Ни один существующий метод не удовлетворяет одновременно шести условиям:

- ▶ non-convex,
- ▶ distributed,
- ▶ finite-sum,
- ▶ similarity-aware (сложность от δ),
- ▶ без full gradient,
- ▶ $\mathcal{O}(d)$ server-memory.

Основная идея NFG-SS

Два рекурсивных оценщика

(а) SARAH-телескоп $v_t^{(s)}$ — аппроксиматор $\nabla(f - f_1)(w_t)$:

$$v_t^{(s)} = v_{t-1}^{(s)} + \frac{1}{b} \sum_{i \in B_t^{(s)}} [\nabla(f_i - f_1)(w_t^{(s)}) - \nabla(f_i - f_1)(w_{t-1}^{(s)})].$$

(б) Среднее $\tilde{v}_t^{(s)}$ по уже посчитанным в эпохе градиентам:

$$\tilde{v}_{t+1}^{(s)} = \frac{t-1}{t} \tilde{v}_t^{(s)} + \frac{1}{tb} \sum_{i \in B_t^{(s)}} \nabla(f_i - f_1)(w_t^{(s)}).$$

Ключевое наблюдение

После полного обхода всех клиентов в эпохе:

$$\tilde{v}_{\lfloor n/b \rfloor + 1}^{(s)} = \frac{1}{n} \sum_t \sum_{i \in B_t^{(s)}} \nabla(f_i - f_1)(w_t^{(s)}).$$

Алгоритм NFG-SS — псевдокод

NoFullGrad SARAH Similarity

Input: $w_0^{(0)} \in \mathbb{R}^d$; $\tilde{v}_1^{(0)} = 0$, $v_0^{(0)} = 0$.

Параметры: stepsize $\theta > 0$, batch size b .

for epochs $s = 0, 1, \dots, S$ do

1. Семплируем непересекающиеся батчи клиентов $B_1^{(s)}, \dots, B_{\lceil n/b \rceil}^{(s)}$ (покрывают всех клиентов).
2. $v_0^{(s)} = v^{(s)}$
3. $w_1^{(s)} = \text{prox}_{\theta f_1}(w_0^{(s)} - \theta v_0^{(s)})$
4. for $t = 1, 2, \dots, \lceil n/b \rceil$ do
 - (a) $\tilde{v}_{t+1}^{(s)} = \frac{t-1}{t} \tilde{v}_t^{(s)} + \frac{1}{tb} \sum_{i \in B_t^{(s)}} \nabla(f_i - f_1)(w_t^{(s)})$
 - (b) $v_t^{(s)} = v_{t-1}^{(s)} + \frac{1}{b} \sum_{i \in B_t^{(s)}} [\nabla(f_i - f_1)(w_t^{(s)}) - \nabla(f_i - f_1)(w_{t-1}^{(s)})]$
 - (c) $w_{t+1}^{(s)} = \arg \min_w \{ \langle v_t^{(s)}, w \rangle + \frac{1}{2\theta} \|w - w_t^{(s)}\|^2 + f_1(w) \}$
5. $w_0^{(s+1)} = w_{\lceil n/b \rceil+1}^{(s)}$, $\tilde{v}_1^{(s+1)} = 0$, $v^{(s+1)} = \tilde{v}_{\lceil n/b \rceil+1}^{(s)}$

Теорема о сходимости

Theorem 1

Пусть выполнены δ -similarity и f ограничена снизу. Запустим NFG-SS с шагом $\theta = c^* b/(\delta n)$, где $c^* = \sqrt{(-13 + \sqrt{185})/(272e)}$. Тогда для достижения

$$\frac{1}{S(n/b+1)} \sum_{s=1}^S \sum_{t=0}^{n/b} \|G_{\theta}(w_t^{(s)})\|^2 \leq \varepsilon^2$$

требуется

$$N_{\text{oracle}} = \mathcal{O}\left(\frac{n\delta\Delta_1}{\varepsilon^2}\right) + \mathcal{O}\left(\frac{n^2\delta^2\Delta_2}{b\varepsilon^2}\right),$$

где $\Delta_1 = f(w^{(0)}) - f^*$, $\Delta_2 = \sum_j \|w_{j+1}^{(0)} - w_j^{(0)}\|^2$.

Слайд 12 — Comparison table


Сравнение методов

Метод	Full grad?	Convexity	Memory	Complexity
SVRS [17]	да	μ -SC	$\mathcal{O}(d)$	$\mathcal{O}\left((n + \sqrt{n}\delta/\mu) \log \frac{1}{\varepsilon}\right)$
AccSVRS [17]	да	μ -SC	$\mathcal{O}(d)$	$\mathcal{O}\left((n + n^{3/4} \sqrt{\delta/\mu}) \log \frac{1}{\varepsilon}\right)$
Shuffled SARAH [2]	нет	μ -SC	$\mathcal{O}(d)$	$\mathcal{O}\left((nL/\mu + n^2\delta/\mu) \log \frac{1}{\varepsilon}\right)$
SILVER [21]	нет	non-convex	$\mathcal{O}(nd)$	$\mathcal{O}\left(n + \delta n^{1/2}/\varepsilon^2\right)$
SPAM [10]	нет	non-convex	$\mathcal{O}(d)$	$\mathcal{O}\left((\delta + \sigma^2)/\varepsilon^2 + \delta\sigma/\varepsilon^3\right)$
NFG-SS (наш)	нет	non-convex	$\mathcal{O}(d)$	$\mathcal{O}\left(n\delta\Delta_1/\varepsilon^2 + n^2\delta^2\Delta_2/(b\varepsilon^2)\right)$

Что показывает таблица

NFG-SS — единственный метод с полным набором свойств: не использует ∇f , не требует выпуклости, держит $\mathcal{O}(d)$ память на сервере, и при этом сложность зависит от similarity-параметра δ , а не L .

Эксперимент: CIFAR-10 / ResNet-18



Test accuracy vs. # transmitted vectors;

Постановка

- ▶ CIFAR-10, ResNet-18 [6, 14].
- ▶ $n = 11$: 1 сервер (f_1) + 10 клиентов.
- ▶ Бейзлайны: SVRS с честным подсчетом полного градиента, FedAvg [18] в communication-matched режиме.

Заключение

Итог работы

Предложен метод NFG-SS — новый распределенный алгоритм для невыпуклой оптимизации под second-order similarity предположением, который полностью устраняет необходимость обновления полного градиента на каждом раунде.

Спасибо за внимание!



Список литературы I

- [1] Yossi Arjevani and Ohad Shamir. Communication complexity of distributed convex learning and optimization. Advances in neural information processing systems, 28, 2015.
- [2] Aleksandr Beznosikov and Martin Takáč. Random-reshuffled sarah does not need full gradient computations. Optimization Letters, 18(3):727–749, 2024.
- [3] Ashok Cutkosky and Francesco Orabona. Momentum-based variance reduction in non-convex sgd, 2020.
- [4] Aaron Defazio, Francis Bach, and Simon Lacoste-Julien. Saga: A fast incremental gradient method with support for non-strongly convex composite objectives. Advances in neural information processing systems, 27, 2014.
- [5] Cong Fang, Chris Junchi Li, Zhouchen Lin, and Tong Zhang. Spider: Near-optimal non-convex optimization via stochastic path-integrated differential estimator. Advances in neural information processing systems, 31, 2018.

Список литературы II

- [6] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 770–778, 2016.
- [7] Hadrien Hendrikx, Lin Xiao, Sebastien Bubeck, Francis Bach, and Laurent Massoulié. Statistically preconditioned accelerated gradient method for distributed optimization. In International conference on machine learning, pages 4203–4227. PMLR, 2020.
- [8] Peter Kairouz and H Brendan McMahan. Advances and open problems in federated learning. Foundations and trends in machine learning, 14(1-2):1–210, 2021.
- [9] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B. Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. arXiv preprint arXiv:2001.08361, 2020.
- [10] Avetik Karagulyan, Egor Shulgin, Abdurakhmon Sadiev, and Peter Richtárik. Spam: Stochastic proximal point method with momentum variance reduction for non-convex cross-device federated learning, 2024.

Список литературы III

- [11] Ahmed Khaled and Chi Jin. Faster federated optimization under second-order similarity. arXiv preprint arXiv:2209.02257, 2022.
- [12] Jakub Konečný, H Brendan McMahan, Felix X Yu, Peter Richtárik, Ananda Theertha Suresh, and Dave Bacon. Federated learning: Strategies for improving communication efficiency. arXiv preprint arXiv:1610.05492, 2016.
- [13] Dmitry Kovalev, Aleksandr Beznosikov, Ekaterina Borodich, Alexander Gasnikov, and Gesualdo Scutari. Optimal gradient sliding and its application to optimal distributed optimization under similarity. Advances in Neural Information Processing Systems, 35:33494–33507, 2022.
- [14] Alex Krizhevsky, Geoffrey Hinton, et al. Learning multiple layers of features from tiny images. 2009.
- [15] Zhize Li, Hongyan Bao, Xiangliang Zhang, and Peter Richtárik. Page: A simple and optimal probabilistic gradient estimator for nonconvex optimization. In International conference on machine learning, pages 6286–6295. PMLR, 2021.

Список литературы IV

- [16] Zhize Li, Slavomír Hanzely, and Peter Richtárik. Zerosarah: Efficient nonconvex finite-sum optimization with zero full gradient computation. arXiv preprint arXiv:2103.01447, 2021.
- [17] Dachao Lin, Yuze Han, Haishan Ye, and Zhihua Zhang. Stochastic distributed optimization under average second-order similarity: Algorithms and analysis. Advances in Neural Information Processing Systems, 36:1849–1862, 2023.
- [18] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Agueray Arcas. Communication-efficient learning of deep networks from decentralized data. In Artificial intelligence and statistics, pages 1273–1282. Pmlr, 2017.
- [19] Daniil Medyakov, Gleb Molodtsov, Savelii Chezhegov, Alexey Rebrikov, and Aleksandr Beznosikov. Variance reduction methods do not need to compute full gradients: Improved efficiency through shuffling. arXiv preprint arXiv:2502.14648, 2025.

Список литературы V

- [20] Lam M Nguyen, Jie Liu, Katya Scheinberg, and Martin Takáč. Sarah: A novel method for machine learning problems using stochastic recursive gradient. In International conference on machine learning, pages 2613–2621. PMLR, 2017.
- [21] Kazusato Oko, Shunta Akiyama, Denny Wu, Tomoya Murata, and Taiji Suzuki. SILVER: Single-loop variance reduction and application to federated learning. In Forty-first International Conference on Machine Learning, 2024.
- [22] Sashank J Reddi, Jakub Konečný, Peter Richtárik, Barnabás Póczós, and Alex Smola. Aide: Fast and communication efficient distributed optimization. arXiv preprint arXiv:1608.06879, 2016.
- [23] Nicolas Roux, Mark Schmidt, and Francis Bach. A stochastic gradient method with an exponential convergence _rate for finite training sets. Advances in neural information processing systems, 25, 2012.

Список литературы VI

- [24] Ohad Shamir, Nati Srebro, and Tong Zhang. Communication-efficient distributed optimization using an approximate newton-type method. In International conference on machine learning, pages 1000–1008. PMLR, 2014.
- [25] Ying Sun, Gesualdo Scutari, and Amir Daneshmand. Distributed optimization based on gradient tracking revisited: Enhancing convergence rate via surrogation. SIAM Journal on Optimization, 32(2):354–385, 2022.
- [26] Shusen Wang, Fred Roosta, Peng Xu, and Michael W Mahoney. Giant: Globally improved approximate newton method for distributed optimization. Advances in neural information processing systems, 31, 2018.
- [27] Yuchen Zhang and Xiao Lin. Disco: Distributed optimization for self-concordant empirical loss. In Francis Bach and David Blei, editors, Proceedings of the 32nd International Conference on Machine Learning, volume 37 of Proceedings of Machine Learning Research, pages 362–370, Lille, France, 07–09 Jul 2015. PMLR.