

Текст выступления

NFG-SS: распределённая невыпуклая оптимизация без полного участия клиентов

Общий хронометраж: 10 минут (9:30 чистой речи + буфер на переключение слайдов). Темп — спокойный, около 150 слов/минуту. Цифры в скобках — ориентир.

Слайд 1 — Титульный слайд

(~20 сек)

Добрый день, уважаемые члены комиссии. Меня зовут Зайнуллин Амир, группа Б05-206д. Тема моей преддипломной работы — локальные методы распределённой оптимизации без подсчёта полного градиента. Метод, который я предлагаю, мы назвали NFG-SS. Научный руководитель — Александр Николаевич Безносиков.

Кратко о плане доклада: сначала я обозначу контекст и поставлю задачу, потом покажу, какие два направления существуют в литературе и какой между ними гар. После этого расскажу про сам алгоритм и теоретический результат. В конце — эксперимент на CIFAR-10 и выводы.

Слайд 2 — Цель и задачи

(~30 сек)

Цель работы — построить распределённый алгоритм для невыпуклой оптимизации, который одновременно использует similarity между данными клиентов для ускорения и при этом не требует вычисления полного градиента ни в одной точке. Дополнительно — линейная по размерности память на сервере, не растущая с числом клиентов.

Задачи делятся на анализ существующих методов в двух направлениях, разработку собственного алгоритма, доказательство его сходимости в невыпуклом случае и экспериментальное сравнение с baseline'ами.

Слайд 3 — Актуальность

(~50 сек)

Зачем нам distributed-сетап. Современные модели и датасеты растут — обучить такое на одной машине нельзя, и распределение по узлам становится обязательным. Но за это надо платить связью: каждый раунд это d -мерные векторы между сервером и каждым клиентом. Метрика прогресса в этой области не число итераций, а общее число transmitted vectors.

Что нам даёт similarity. Если данные клиентов из одного распределения, локальные функции близки в моменте — норма разности гессианов ограничена параметром δ . И в реальных задачах δ намного меньше параметра гладкости L .

Проблема в литературе. Есть две линии работ. Similarity-методы — используют δ для ускорения, но в начале каждой эпохи дёргают всех клиентов за полным градиентом. И no-full-gradient методы — они избегают этого, но не учитывают δ . Их сложность зависит от L , и весь выигрыш similarity теряется. Эти линии до сих пор развивались отдельно.

Слайд 4 — Постановка задачи

(~45 сек)

Формальная задача — стандартная распределённая finite-sum: минимизируем среднее по узлам, где каждая локальная функция f_i — empirical mean по своему датасету. Один узел — сервер, хранит функцию f_1 ; остальные $n - 1$ — клиенты.

Теперь зачем нам нужно прокс-разложение. У глобальной функции f нет полезной глобальной гладкости — для нейросетей L либо неизвестен, либо чудовищно велик. И выпуклости тоже нет. То есть мы не можем напрямую делать обычный градиентный спуск и надеяться на классические descent-неравенства.

Решение: раскладываем f на серверную часть f_1 и клиентскую разность $(f - f_1)$. Серверная часть полностью доступна на сервере, поэтому её мы обрабатываем через прокс-оператор точно — это бесплатно. А клиентскую часть нужно оценить стохастически, без полного обхода всех клиентов. Это и есть основная работа нашего алгоритма.

Слайд 5 — Second-order similarity (~40 сек)

Формальное определение: норма разности гессианов локальной функции и среднего ограничена δ во всех точках.

Это допущение строго слабее, чем L -гладкость: при L -smoothness δ автоматически не превосходит $2L$. Откуда вообще берётся δ ? Из теории обучения: если локальные датасеты — i.i.d. семплы из общего распределения размера m , то δ скейлится как L делённое на корень из m . В современном ML m велико — отсюда $\delta \ll L$.

Почему это критично. Сложность similarity-методов масштабируется как δ , а не L — это выигрыш фактора L/δ по communication. Грубо говоря, similarity — это бесплатная структура, и грамотный алгоритм её обязан использовать.

Слайд 6 — Связанная работа: similarity-методы (~40 сек)

Первая линия работ. Начало — DANE Шамира 2014 года, Newton-type для quadratic objectives. Дальнейшие улучшения — AIDE, DISCO, GIANT. Параллельно — SONATA и Accelerated Extragradient Ковалёва 2022, которые достигают оптимального communication-bound $\sqrt{\delta/\mu}$ под логарифмом.

Стохастическая ветвь: SVRP и Catalyzed SVRP Халеда и Цзина — variance reduction с прокс-операторами. И SVRS, AccSVRS Lin et al. 2023 с оптимальной сложностью $n + n^{3/4}\sqrt{\delta/\mu}$ под логарифмом.

Общий минус всей этой группы — в начале каждой эпохи каждый клиент шлёт серверу свой ∇f_i , это $\mathcal{O}(n)$ векторов на каждый refresh. Плюс везде нужен strong convexity, что для нейросетей нереалистично.

Слайд 7 — Связанная работа: no-full-gradient методы (~25 сек)

Вторая линия — методы без full grad. SAG и SAGA — таблица всех градиентов, дорогая память. SARAH и SPIDER — recursive estimator, но периодически дёргают полный градиент. STORM и PAGE — momentum-based или probabilistic switching. И полностью без full grad: ZeroSARAH 2021, Shuffled SARAH Безносикова–Такача 2024, и Medyakov et al. 2025, где anchor заменён на running-mean по random reshuffle.

Общий минус — все методы centralized и не учитывают similarity. Сложность зависит от L .

Слайд 8 — Пересечение и гар (~40 сек)

Что находится на пересечении двух линий и почему этого недостаточно. Beznosikov и Takáč 2024 — Shuffled SARAH под similarity, но strongly convex и centralized, не distributed. SILVER, Oko et al. 2024 — non-convex distributed без full grad, но платит $\mathcal{O}(nd)$ памяти на сервере, по вектору на клиента. SPAM, Karagulyan 2024 — similarity-aware без full grad, но в stochastic regime, не использует finite-sum и не даёт оптимальной $1/\varepsilon^2$ сходимости в нашем смысле.

Незакрытая ниша — метод, удовлетворяющий одновременно шести требованиям: non-convex,

distributed, finite-sum, similarity-aware, без full gradient, и $\mathcal{O}(d)$ память. NFG-SS — первый такой.

Слайд 9 — Основная идея NFG-SS

(~60 сек)

Это центральный слайд алгоритмической части. Мы поддерживаем два рекурсивных оценщика. Первый — SARAH-телескоп v_t : классическая low-variance конструкция через разности градиентов на соседних итерациях. Второй — running mean $\tilde{v}_t$ по уже посчитанным в эпохе градиентам, со специальными коэффициентами $(t-1)/t$ и $1/(tb)$.

Ключевое наблюдение: после полного обхода всех клиентов в эпохе running-mean — это усреднение градиентов клиентов в разных точках траектории. Если бы все эти точки совпадали с финальной, это был бы точно полный градиент в этой точке. На практике точки разные, но bias ограничен суммой квадратов сдвигов итераторов внутри эпохи — это то, что мы можем контролировать через step size.

Главный trick: на следующей эпохе берём $v_0^{(s+1)}$ равным финальному running-mean из предыдущей эпохи. Анкер бесплатный — никакого full gradient не считается ни в одной точке.

Слайд 10 — Алгоритм NFG-SS — псевдокод

(~40 сек)

Псевдокод формализует идею. Ключевой момент — шаг 2: $v_0^{(s)}$ это carry-over running-mean из эпохи $s-1$, а не свежий полный градиент. Внутри эпохи на каждой итерации параллельно обновляем оба оценщика — running-mean (a) и SARAH-телескоп (b) — и делаем прокс-шаг (c). В конце эпохи финальное значение running-mean становится анкером для следующей эпохи (шаг 5). Полный градиент не считается нигде.

Слайд 11 — Теорема о сходимости

(~45 сек)

Теорема даёт два слагаемых в oracle complexity. Первое — $n\delta\Delta_1/\varepsilon^2$ — это слагаемое типа no-full-grad SARAH из Medyakov et al., но с δ вместо L . Именно здесь сохраняется выигрыш similarity. Второе слагаемое — $n^2\delta^2\Delta_2/(b\varepsilon^2)$ — плата за то, что инициализация эпохи строится по итератам предыдущей.

Особо подчеркну три вещи. Первое: никакого предположения о выпуклости. Второе: никакого вычисления ∇f ни в одной точке. Третье: сложность зависит от similarity-параметра δ , а не от L . Так как в реальных задачах $\delta \ll L$, это означает кратное ускорение по сравнению с любым существующим no-full-grad методом.

Слайд 12 — Сравнительная таблица

(~30 сек)

Сводная таблица позиционирует NFG-SS среди конкурентов. SVRS и AccSVRS требуют full grad и strong convexity. Shuffled SARAH без full grad, но всё ещё strongly convex и зависит от L в первом слагаемом. SILVER non-convex без full grad, но платит $\mathcal{O}(nd)$ памятью на сервере. SPAM в stochastic regime с $1/\varepsilon^3$.

NFG-SS — единственный метод с полным набором свойств одновременно.

Слайд 13 — Эксперимент на CIFAR-10 / ResNet-18

(~55 сек)

Эмпирическая валидация. CIFAR-10, модель ResNet-18, 11 узлов: один сервер и 10 клиентов с uniform random partition. Сравнение с двумя baseline'ами: SVRS — в точной формулировке Lin et al. 2023, с честным full-gradient anchor в начале каждой эпохи. И FedAvg — в communication-matched режиме, то есть бюджет transmitted vectors одинаков.

На графике — test accuracy в зависимости от числа transmitted vectors. Кривая — медиана по трём random seeds, лента — min-max envelope. NFG-SS обгоняет SVRS примерно после тысячи

векторов и удерживает преимущество до конца. Финальная медиана: NFG-SS — около 0.79, SVRS — 0.74, FedAvg — 0.71 при одинаковом бюджете 2000 transmitted vectors.

Важно: ленты NFG-SS и SVRS на финальном плато не пересекаются — разница устойчива по сидам.

Слайд 14 — Заключение

(~30 сек)

Подытожу. Предложен метод NFG-SS — distributed variance-reduced алгоритм для невыпуклой оптимизации под second-order similarity. Главный результат: это первый distributed-метод, использующий similarity без полного участия клиентов ни в одной точке. Сложность зависит от δ , не от L ; невыпуклый случай; память на сервере $\mathcal{O}(d)$. Эмпирически dominates SVRS и communication-matched FedAvg.

Направления развития: acceleration через Catalyst-обёртку, снятие предположения о полном покрытии клиентов в эпохе, и расширение на decentralized топологии.

Слайд 15 — Спасибо за внимание

(~5 сек)

Спасибо за внимание. Готов ответить на ваши вопросы.

Подсказки для подготовки:

- Самые «дорогие» по смыслу слайды — 3 (актуальность), 4 (постановка с прокс-разложением), 8 (gap), 9 (идея), 11 (теорема), 13 (эксперимент). На них стоит не торопиться.
- Слайды 6, 7 (related work) — пройти средним темпом, не вязнуть в названиях методов; логика группировки видна на слайде сама.
- На слайде 10 (псевдокод) не зачитывай построчно. Покажи на шаги 2 и 5 — где carry-over и где никакого full grad.
- На слайде 13 после описания постановки сразу поверни голову к графику и пробеги взглядом снизу вверх: NFG-SS, SVRS, FedAvg.
- Возможные вопросы: «почему именно δ , а не L ?» (similarity — структурное предположение, $\delta \ll L$ при i.i.d. данных). «Зачем второй оценщик $\tilde{v}$?» (анкер для следующей эпохи бесплатно из уже посчитанных градиентов). «Что если $\delta \approx L$?» (тогда наш метод не лучше обычного no-full-grad — выигрыш именно в режиме $\delta \ll L$).